

Modalidade: PIDTI

RAG-BAYESIANO PARA AUDITORIA EXPLICÁVEL DE INCONSISTÊNCIAS CADASTRAIS E DOCUMENTAIS EM PROCESSOS DE ANÁLISE DE CRÉDITO NO DF/RIDE

Projeto de Desenvolvimento Tecnológico e Inovação PIDTI

1. TEMA E DELIMITAÇÃO DO ESTUDO

O projeto propõe um MVP de sistema de IA que integra arquitetura RAG (Retrieval-Augmented Generation) e inferência bayesiana para auditar inconsistências cadastrais e documentais em processos de crédito no DF e RIDE. O escopo inclui: framework de IA auditável com bases de dados locais (CODEPLAN, Portal da Transparência, Cadastro Territorial); aplicação do Teorema de Bayes para atualização iterativa de probabilidade de suspeita; e geração de relatórios em linguagem natural para governança algorítmica.

2. DEFINIÇÃO DO PROBLEMA

Como mitigar vieses sociais e garantir a explicabilidade em sistemas de análise de crédito automatizados no DF/RIDE, utilizando RAG e inferência bayesiana para identificar inconsistências de forma auditável e rastreável?

3. HIPÓTESES E PRESSUPOSTOS

H1: A integração RAG-Bayesiana gera *scores* de suspeita mais calibrados e rastreáveis que modelos preditivos estáticos.

H2: A explicitação dos cálculos probabilísticos em linguagem natural aumenta a confiabilidade das decisões, reduzindo vieses contra populações vulneráveis.

H3: O uso de dados locais (CODEPLAN/GDF) para calibração do *prior* bayesiano supera modelos genéricos nacionais em relevância demográfica.

4. OBJETIVOS:

4.1 Objetivo Geral

Desenvolver e validar um MVP de framework de IA (RAG + Bayesiano) para identificar inconsistências em processos de crédito, com justificativas auditáveis, visando registro de software no NIT/UnDF.

4.2 Objetivos Específicos

- Catalogar padrões de inconsistência documental calibrados por dados abertos locais.
- Construir módulo RAG (Python + LangChain + FAISS) para extração de evidências.
- Implementar motor bayesiano (PyMC) para atualização de probabilidade posterior.
- Desenvolver interface de explicabilidade (XAI) acessível a gestores públicos.
- Avaliar o protótipo por cenários sintéticos, *ablation study* e equidade algorítmica.

5. JUSTIFICATIVA

Fraudes cadastrais são vetores de risco críticos. No DF/RIDE, populações vulneráveis são as mais afetadas. A inovação reside na integração de três camadas: RAG (evidências reais), inferência bayesiana (rigor matemático/auditabilidade) e XAI (transparência/LGPD). O projeto, inédito no contexto local, tem impacto social ao permitir que órgãos como BRB ou Secretaria de Economia modernizem a análise de risco com soberania de dados e foco na inclusão financeira.

6. DISCUSSÃO TEÓRICA E METODOLÓGICA

6.1 Relação com Inovação Tecnológica (PIDTI)

O projeto enquadra-se na modalidade PIDTI por propor o desenvolvimento de um artefato tecnológico original que resolve um problema real do setor financeiro com custo operacional zero. O produto final (MVP) utilizará exclusivamente tecnologias de código aberto (Open Source), garantindo soberania de dados e exequibilidade técnica sem dependência de créditos externos de processamento. O processamento será 100% offline em servidor local via Ollama, garantindo que nenhum dado de cidadão do DF trafegue por nuvens de terceiros, assegurando conformidade estrita com a LGPD e o sigilo bancário.

6.2 Referencial Teórico

O projeto apoia-se em quatro pilares teóricos interconectados, organizados em camadas funcionais:

Arquitetura RAG (Retrieval-Augmented Generation) — Camada de Evidência:

Introduzida por Lewis et al. (2020), a arquitetura RAG separa o raciocínio em duas etapas: recuperação (retrieval), que busca documentos relevantes em base vetorial, e geração (generation), que produz resposta fundamentada nas evidências recuperadas. Essa abordagem reduz alucinações dos modelos de linguagem e melhora a rastreabilidade das respostas — requisito essencial para aplicações em crédito e compliance. No presente projeto, os dados públicos (CODEPLAN, Portal da Transparência, Cadastro Territorial) são tratados como evidência contextual auditável, não como ground truth de fraude, o que é metodologicamente mais defensável dado o tipo de base disponível.

Inferência Bayesiana Aplicada — Camada Probabilística:

Neste projeto, a inferência bayesiana é usada para dar um tratamento matemático claro e auditável às evidências encontradas pelo sistema RAG. Em vez de considerar que toda informação recuperada é automaticamente verdadeira ou conclusiva, o modelo reconhece que os documentos e trechos encontrados podem ter diferentes graus de relevância, qualidade e confiabilidade.

Assim, o sistema parte de uma probabilidade inicial de suspeita, chamada prior, calibrada com dados territoriais e socioeconômicos do DF e da RIDE. Em seguida, essa probabilidade vai sendo atualizada à medida que o módulo RAG encontra novas evidências documentais, como divergência entre CPF e data de nascimento, endereço não localizado no Cadastro Territorial ou renda incompatível com o perfil da região informada.

A principal vantagem dessa abordagem é que cada nova evidência não entra no sistema de forma “cega”. Ela é analisada de acordo com três aspectos: sua relevância para o caso; o tipo de inconsistência que representa; e a confiabilidade da fonte em que foi encontrada.

Com isso, o sistema consegue aumentar ou reduzir a suspeita de forma gradual, transparente e justificável, em vez de produzir apenas um resultado final sem explicação.

Na prática, isso significa que o modelo pode informar não apenas qual foi a pontuação de suspeita de um processo, mas também por que ela mudou. Por exemplo: a suspeita inicial

pode subir após a identificação de um endereço inexistente, aumentar novamente com uma divergência em dados pessoais e depois ser ajustada conforme o peso e a qualidade de cada evidência recuperada.

Dessa forma, a inferência bayesiana torna o RAG mais confiável para uso em auditoria, porque transforma a recuperação de documentos em um processo de decisão explicável, rastreável e compatível com revisão humana. O resultado é um sistema em que a justificativa da decisão faz parte do próprio funcionamento do modelo, e não apenas de uma explicação acrescentada ao final.

Explicabilidade e Governança de IA (XAI) — Camada Decisória:

A Camada Decisória de Explicabilidade e Governança (XAI) atua como interface tradutora entre a inferência probabilística bayesiana e a tomada de decisão humana, convertendo atualizações sequenciais de suspeita e evidências recuperadas pelo módulo RAG em narrativas técnicas acessíveis. Por meio de templates estruturados, o sistema decompõe o cálculo posterior em contribuições individuais de cada inconsistência documental (ex.: endereço não localizado no Cadastro Territorial, divergência entre CPF e data de nascimento), gerando justificativas rastreáveis que explicitam pesos, fontes de validação e variações percentuais. Dessa forma, essa arquitetura atende diretamente aos princípios de transparência, auditabilidade e contestabilidade do NIST AI RMF 1.0 e da LGPD (Lei 13.709/2018), garantindo que analistas e órgãos de controle compreendam, validem e revisem cada etapa do raciocínio algorítmico, com registro imutável de todo o pipeline de recuperação, tipificação lógica e atualização de prior.

Além da transparência qualitativa, a camada integra mecanismos quantitativos de apoio à decisão, traduzindo o score probabilístico em métricas operacionais de risco, como simulações de políticas de corte (cutoff) e estimativas de perda esperada. Ao modelar como diferentes limiares de suspeita impactam taxas de aprovação, falsos positivos e necessidades de provisionamento, o framework permite que instituições financeiras e órgãos públicos calibrem seu apetite ao risco de forma dinâmica e empiricamente justificada. Operando sob o paradigma human-in-the-loop, o sistema não automatiza concessões ou negações, mas emite pareceres técnicos com recomendações condicionais, assegurando responsabilidade decisória humana, mitigando vieses territoriais históricos no DF/RIDE e alinhando a inovação

tecnológica às exigências de governança regulatória, soberania de dados e inclusão financeira responsável.

Lógica de Primeira Ordem e Representação do Conhecimento — Camada de Tipificação:

A camada de Lógica de Primeira Ordem (FOL) atua como filtro simbólico entre a recuperação RAG (via FAISS) e o motor bayesiano (PyMC). Ela converte fragmentos textuais em evidências formalmente tipificadas, garantindo que o motor probabilístico receba sinais estruturados, essenciais para calibração e rastreabilidade. A FOL oferece três vantagens: 1) classificação determinística e inspecionável por especialistas (ex: incompatibilidade territorial), ao contrário de classificadores neurais opacos; 2) associação formal da verossimilhança $P(E_i|H)$ a cada inconsistência, justificando a atualização bayesiana; e 3) base de regras auditável e ajustável por analistas de crédito sem retreinamento, atendendo aos requisitos de contestabilidade (LGPD, NIST AI RMF). A implementação usará funções Python puras sobre entidades extraídas pelo LangChain, sem motor de inferência externo, seguindo o padrão neurossimbólico consolidado (Chen et al., 2024; Hakim et al., 2025).

6.3 Procedimentos Metodológicos:

A pesquisa adotará abordagem organizada em quatro etapas:

Etapas 1 — Modelagem do Prior e Infraestrutura Local: Curadoria de bases públicas (CODEPLAN/PDAD) e configuração do ambiente local de inferência utilizando a stack Ollama + Llama-3/Mistral. Os dados públicos são tratados como fonte de contexto e prior bayesiano — não como base de treinamento supervisionado — o que elimina a exigência de rótulos de fraude e é metodologicamente alinhado ao tipo de dado disponível. Geração de Digital Twins (Gêmeos Digitais) de dados cadastrais, calibrados estatisticamente pela PDAD/CODEPLAN para validação em ambiente controlado.

Etapas 2 — Desenvolvimento do Módulo RAG: Construção do índice vetorial local com FAISS e implementação do pipeline de recuperação com LangChain, integrando regras de lógica formal para tipificação de inconsistências. Validação do sistema em ambiente de sandbox com dados sintéticos demograficamente coerentes com a RIDE.

Etapas 3 — Motor Bayesiano e Camada de Apoio à Decisão: Implementação do motor probabilístico via PyMC (v5.0+) e integração da camada de apoio à decisão financeira, incluindo simulações de cutoff e perda esperada, e auditoria de viés geográfico para garantir

que as taxas de erro sejam equânimes entre as diferentes Regiões Administrativas (RAs) do DF. Nota: RAROC pode ser incorporado como extensão demonstrativa, mas não constitui o núcleo metodológico do MVP — o que evita comprometer a proposta com a necessidade de parâmetros operacionais completos (PD, LGD, EAD, custo de capital) não disponíveis nas bases públicas.

Etapa 4 — Transferência e Proteção: Documentação do MVP, submissão de pedido de registro de software ao NIT/UnDF e elaboração de Plano de Transferência Tecnológica para o GDF.

A validação do protótipo seguirá quatro estratégias complementares: (i) validação por cenários e casos sintéticos (casos normais, com inconsistência leve, com inconsistência grave e casos ambíguos); (ii) ablation study para medir a contribuição isolada de cada componente (Bayes sem RAG, RAG sem Bayes, sistema completo); (iii) avaliação de calibração e utilidade decisória, não apenas precisão/F1; e (iv) avaliação com gold set revisado manualmente, mesmo que limitado, para ancoragem da performance.

6.4 Arquitetura do Framework RAG-Audit-Bayesiano

O framework é organizado em três camadas funcionais integradas:

- Camada de Evidência (RAG): recuperação semântica de documentos, normas e fontes territoriais; tipificação formal de inconsistências via lógica de primeira ordem.
- Camada Probabilística (Bayes): combinação de sinais e atualização iterativa da probabilidade posterior de suspeita a cada nova evidência recuperada.
- Camada Decisória (XAI + Apoio à Decisão): geração de relatório explicável em linguagem natural, encaminhamento para revisão humana e simulações de impacto em política de corte e perda esperada.

Stack Tecnológico: Python 3.11+, LangChain, PyMC (v5+), SDV (Synthetic Data Vault), FAISS, Ollama (Local LLM Inference), Git/GitHub.

Infraestrutura: O processamento será realizado integralmente em hardware local (CPU/GPU), sem custos de subscrição ou consumo de nuvem.

7. CRONOGRAMA DE EXECUÇÃO:

Etapa	Atividades Principais	Trimestre
Setup & Dados	Revisão, curadoria (CODEPLAN) e config. Ollama	1
Modelagem	Definição do <i>prior</i>, regras de Lógica de 1ª Ordem	1, 2
Integração	Banco FAISS, pipeline LangChain, PyMC	2, 3
Testes/MVP	<i>Ablation study</i>, apoio à decisão, impacto de <i>cutoff</i>	3, 4
Entrega Final	Docker, Registro Software, Guia, Relatório, Artigo	4

8. REFERÊNCIAS:

BANCO CENTRAL DO BRASIL. *Relatório de Estabilidade Financeira*. Brasília: BCB, 2023.

CHEN, Z. et al. RuleRAG: Rule-Guided Retrieval-Augmented Generation with Language Models for Question Answering. In: CONFERENCE ON EMPIRICAL METHODS IN NATURAL LANGUAGE PROCESSING (EMNLP), 2024, Miami. *Proceedings...* Miami: ACL Anthology, 2024.

CODEPLAN. *Pesquisa Distrital por Amostra de Domicílios (PDAD)*. Brasília: Companhia de Planejamento do Distrito Federal, 2021.

GELMAN, A. et al. *Bayesian Data Analysis*. 3. ed. Boca Raton: CRC Press, 2013.

HAKIM, S. B. et al. SymRAG: Efficient Neuro-Symbolic Retrieval-Augmented Generation through Adaptive Query Routing. *arXiv:2506.12981*, 2025.

LEWIS, P. et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. In: NEURIPS, 2020. *Anais...*

NIST. *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*. Gaithersburg: NIST, 2023.

PYMC TEAM. *PyMC: A Modern, Architecture-Independent Interface for Probabilistic Programming*, 2024.